

K-EXAONE API 사용 가이드

1. API 사용 방법

Dedicated Endpoints inference 요청 예시:

None

```
curl -X POST https://api.friendly.ai/dedicated/v1/chat/completions \
-H "Authorization: Bearer $TOKEN" \
-H "Content-Type: application/json" \
-d '{
  "model": "(endpoint-id)",
  "messages": [
    {
      "role": "system",
      "content": "You are a helpful assistant."
    },
    {
      "role": "user",
      "content": "Tell me a funny joke."
    }
  ]
}'
```

- **\$TOKEN**: 전달받은 API Key (flp_로 시작)
- **model**: K-EXAONE-236B-A23B 모델이 배포된 **Endpoint ID**

API 스펙: <https://friendly.ai/docs/openapi/dedicated/inference/chat-completions>

2. Reasoning / Reasoning Parser

K-EXAONE 모델은 Controllable Reasoning 기능을 지원합니다 (default: true).

Reasoning을 비활성화하면 응답 속도를 단축할 수 있습니다.

None

```
"chat_template_kwargs": {
  "enable_thinking": false
}
```

parse_reasoning 옵션을 비활성화하면 reasoning 내용을 raw 응답에 함께 반환합니다 (default: true).

None

```
"parse_reasoning": false
```

관련 가이드: <https://friendly.ai/docs/guides/reasoning#usage-controllable-reasoning-models>

3. Stream 기능

응답을 실시간으로 받아보기 위해 `stream` 옵션 사용을 권장합니다 (default: false). 긴 응답 또는 디버깅 시 유용합니다.

None

```
"stream": true
```

관련 가이드: <https://friendly.ai/docs/openapi/dedicated/inference/chat-completions#body-stream-one-of-0>